Модул 2

(Збір і аналіз реального датасету → очистка/підготовка → візуалізація та інтерпретація). Усі варіанти можна виконувати в Python (Pandas + NumPy + Matplotlib) з джерел **open data**.

Загальні вимоги (однакові для всіх варіантів)

Для свого варіанту студент має:

1. **Зібрати реальний датасет** (CSV/JSON/API) і зберегти в `data/raw/`
2. Описати дані: розмір, колонки, типи, пропуски, дублікати
3. **Очистити/підготувати**:
   - пропуски (мін. 2 стратегії)
   - дублікати
   - приведення типів (дати/числа/категорії)
   - (за потреби) outliers / некоректні значення
4. **Візуалізація** (мінімум 4 графіки):
   - 1 розподіл (гістограма/boxplot)
   - 1 залежність (scatter/line)
   - 1 порівняння груп (bar)
   - 1 "пояснювальний" графік (тренд/топ-10/heatmap кореляцій)
5. **Інтерпретація**: 5–10 висновків на основі графіків і статистики
6. Експорт:
   - `data/processed/clean.csv`
   - `artifacts/reports/report.md` (опис кроків + графіки)

30 варіантів (завдання)

B1. Якість повітря (PM2.5/PM10)

Джерело: open data по якості повітря (місто/країна)
Питання: як змінюється рівень забруднення по днях/сезонах?
Візуалізації: тренд у часі, boxplot по місяцях, топ-дні з піками, кореляція з погодою (якщо є).

B2. Погода (температура/вітер/вологість)

Джерело: погодний API або архів CSV
Питання: які закономірності температури/вітру за період?
Графіки: line (темп), гістограма, scatter temp-вологість, bar по місяцях.

B3. Землетруси

Джерело: GeoJSON/CSV (стрічка подій)
Питання: де і які магнітуди трапляються найчастіше?
Графіки: розподіл магнітуд, топ-регіони, тренд кількості подій, залежність depth–magnitude.

B4. ДТП

Джерело: відкриті дані міста/країни
Питання: коли (година/день тижня) більше ДТП і де?
Графіки: bar по годинах, bar по днях тижня, топ-локації, тренд по місяцях.

B5. Пожежі/надзвичайні події
Джерело: open incidents dataset
Питання: сезонність та райони з найбільшою кількістю інцидентів.
Графіки: тренд, топ-райони, розподіл часу реагування (якщо є), boxplot.

B6. COVID/грип (епіддані)
Джерело: відкритий набір по захворюваності
Питання: хвилі, піки, порівняння регіонів.
Графіки: line, bar top регіонів, moving average, heatmap (регіон×тиждень).

B7. Ціни на пальне
Джерело: open prices dataset
Питання: тренди і різниця між мережами/регіонами.
Графіки: line, boxplot по брендах, bar по регіонах, топ-аномальні дні.

B8. Курси валют (щоденні)
Джерело: API центробанку або фінансові дані
Питання: волатильність, тренд, порівняння 2–3 валют.
Графіки: line, гістограма daily returns, rolling std, scatter двох валют.

B9. Ціни на нерухомість (оголошення)
Джерело: відкритий CSV (або dataset з Kaggle/open data)
Питання: ціна/м² за районами, залежність від площі/кімнат.
Графіки: scatter area–price, boxplot по районах, bar топ-районів, гістограма price/m².

B10. Оренда житла
Джерело: open dataset
Питання: що найбільше впливає на орендну плату (район, кімнати, площа)?
Графіки: boxplot по районах, scatter, bar, кореляції.

B11. Ринок праці (вакансії)
Джерело: open вакансії dataset (публічні)
Питання: найпопулярніші навички та зарплатні діапазони.
Графіки: топ-10 навичок, boxplot salary по ролях, тренд (якщо є дата), bar по містах.

B12. Зарплати по галузях
Джерело: статистика/відкриті дані
Питання: порівняти регіони/галузі, знайти аномалії.
Графіки: bar, boxplot, heatmap “регіон×галузь”, гістограма.

B13. Енергоспоживання
Джерело: open dataset smart-meter/міський
Питання: пікові години, сезонність, різниця вихідні/будні.
Графіки: line по добі, bar вихідні/будні, heatmap година×день, boxplot.

B14. Транспорт (GPS/маршрути/затори)
Джерело: open transit dataset
Питання: середні затримки по маршрутах/годинах.
Графіки: bar маршрутів, line по годинах, boxplot, топ-аномалії.

B15. Авіарейси/затримки
Джерело: dataset про рейси
Питання: які фактори пов'язані із затримками?
Графіки: гістограма delay, bar по авіакомпаніях, scatter distance–delay, тренд.

B16. Продажі магазину (retail)
Джерело: реальний retail dataset
Питання: сезонність, топ категорій, середній чек.
Графіки: line revenue, bar топ категорій, boxplot чек, histogram.

B17. E-commerce поведінка (перегляди/кошик/покупки)
Джерело: поведінковий dataset
Питання: конверсія по категоріях/пристроях.
Графіки: bar conversion, scatter views–buys, топ-10 товарів, heatmap.

B18. Соцмережі (пости/реакції)
Джерело: dataset сторінки/каналу (публічні дані)
Питання: що впливає на engagement (час, тип контенту)?
Графіки: bar тип контенту, line по днях, histogram engagement, top posts.

B19. YouTube/TikTok статистика (публічні)
Джерело: dataset trending videos (open)
Питання: які характеристики пов'язані з переглядами/лайками?
Графіки: scatter views–likes, boxplot по категоріях, топ каналів, histogram.

B20. Книги/рейтинги
Джерело: dataset книг (жанр, рейтинг, сторінки)
Питання: залежність рейтингу від жанру/обсягу.
Графіки: boxplot rating по жанрах, scatter pages–rating, bar топ авторів, histogram.

B21. Фільми (IMDb/TMDb dataset)
Джерело: відкритий dataset фільмів
Питання: рейтинг vs бюджет/жанр/рік.
Графіки: line по роках, boxplot по жанрах, scatter бюджет–рейтинг, топ-10.

B22. Спорт (матчі/гравці)
Джерело: dataset матчів/статистики
Питання: тренд результативності, домашні/виїзні відмінності.
Графіки: line, bar, boxplot, scatter.

B23. Освіта (успішність студентів)
Джерело: dataset оцінок/відвідуваності
Питання: зв'язок attendance–grade; групові відмінності.
Графіки: scatter, boxplot, bar по групах, histogram.

B24. Банківські транзакції (анонімізовані)
Джерело: відкритий dataset транзакцій
Питання: розподіл сум, топ категорій, аномалії.
Графіки: histogram amount, boxplot by category, top merchants, time trend.

B25. Шахрайство (fraud)
Джерело: відкритий fraud dataset
Питання: які ознаки відрізняють fraud від non-fraud?
Графіки: порівняльні гістограми, boxplot, кореляції, bar часток.

B26. Медичні показники (анонімізовані)
Джерело: dataset (BMI, age, blood pressure)
Питання: ризикові групи, розподіли та залежності.
Графіки: histogram, scatter, boxplot, heatmap.

B27. Демографія регіонів
Джерело: відкриті статистичні дані
Питання: міграція/народжуваність/структура віку по регіонах.
Графіки: bar, line, heatmap, top-10.

B28. Туризм (потоки/відвідування)
Джерело: open tourism stats
Питання: сезонність, країни-лідери, вплив подій.
Графіки: line, bar топ країн, boxplot сезонів, histogram.

B29. Екологія (викиди/переробка відходів)
Джерело: open environmental dataset
Питання: порівняння регіонів, тренди, аномалії.
Графіки: line, bar, boxplot, кореляції.

B30. Комбінований проєкт (2 джерела даних)
Джерело: 2 набори (наприклад: погода + якість повітря / вакансії + зарплати)
Завдання: об'єднати по ключу (дата/місто/регіон) і зробити спільний аналіз.
Графіки: мінімум 5, включно з порівнянням до/після об'єднання.

Формат здачі (для всіх)

- `data/raw/source.*` (вихідні дані)
- `data/processed/clean.csv`
- `artifacts/reports/report.md` + `artifacts/reports/*.png` (графіки)

- `src/analysis.py` або ноутбук `notebooks/analysis.ipynb`
- короткий висновок (5-10 пунктів)